

Аутоматска транскрипција говора за српски језик

Стефан Јевтић ми241043

ментор проф. др Младен Николић



УВОД

- Представља област вештачке интелигенције која се бави интеракцијом између рачунара и природног језика
- Подразумева претварање говора у текст
- Кључна технологија у оквиру обраде природних језика
- Широк спектар примена



Примене

- Претраживање садржаја путем говора (енг. voice input)
- Генерисање титлова
- Анализа говора у правним и медицинским условима
- Унапређење корисничког искуства у разним апликацијама (нпр. диктирање порука уместо куцања, Amazon Alexa, ...)



Предности

- Брза и ефикасна обрада великих количина аудио-садржаја
- Елиминисање потребе за заморном ручном транскрипцијом
- Повећање приступачности садржаја особама са оштећењем слуха



Изазови

- Отежано и непрецизно препознавање говора у условима позадинске буке
- Проблеми при обради нејасног изговора и специфичних акцената
- Отежано препознавање стручних и специфичних термина




OpenAI Whisper

- Користи дубоке неуронске мреже и encoder–decoder архитектуру засновану на Transformer-има
- Encoder користи конволутивне слојеве, GELU активациону функцију, позиционо кодирање и механизме пажње
- Decoder користи токенске репрезентације и претходно научене позиционе информације за генерисање текста
- Велика и разноврсна база за обуку модела доприноси робусности на различитим акцентима и позадинској буци



OpenAI Whisper



Коришћени скупови података

- classla/ParlaSpeech-SR – 277.764 audio zapisa (896 h)
- google/fleurs – 2919 audio zapisa (10.44 h)
- mozilla-foundation/common_voice_17_0 – 9000 audio zapisa (6.76 h)
- Коначни train/validation/test скупови обједињују одговарајуће делове сва три корпуса



Технике тренинга

- PEFT и LORA
- AdamW оптимизатор
- Weight decay (L2) регуларизација
- Linear Learning Rate scheduler
- Early stopping



Технике тренинга и евалуације

- Нормализација речи
- Одређивање фреквенције речи
- Провера правописа



Хиперпараметри тренинга

- learning_rate
- weight_decay
- dropout
- batch_size
- gradient_accumulation_steps
- max_steps
- eval_steps
- warmup_steps



Варирање вредности хиперпараметара код модела v2

- `weight_decay`: {0.001, 0.01, 0.1, 0.5}
- `learning_rate`: {0.0005, 0.0007, 0.0009, 0.002, 0.005}
- Оптимални резултати се постижу за `weight_decay=0.001` и `learning_rate=0.0009`



Варирање вредности хиперпараметара код модела v3

- `weight_decay`: {0.001, 0.005, 0.01, 0.05}
- `learning_rate`: {0.0006, 0.0009, 0.002, 0.005}
- Оптимални резултати се постижу за `weight_decay=0.005` и `learning_rate=0.002`




Евалуација модела


- Извршена је кроз метрике WER и CER
- $WER = (S + D + I) / N_{words}$
- $CER = (S + D + I) / N_{chars}$
- Предности метрика су једноставност израчунавања и директно поређење резултата
- Недостатак представља изостанак семантичке и контекстуалне евалуације



Утицај промене `weight_decay` на функцију грешке код модела v2



Утицај промене `learning_rate` на функцију грешке код модела v2



Карактеристичне грешке модела whisper-large-v2

- Акустичне халуцинације
- Ограничење лексичког фонда

Референтни текст	Предвиђање модела	Тип грешке
државни орган	државниорган	Неадекватно спајање речи
погрешио сам	спасибо	Халуцинација (страни језик)
ти ти ти	т т т	Неадекватна транскрипција репетиције
хајде да то	цхајде да то	Грешка у транслитерацији
онај период од	истекнао	Лексичка супституција
кућа	врућа	Погрешно предвиђена реч (акустичка сличност)
у скупштини	у скупштину	Погрешан падеж (непостојећи облик у речнику)



Резултати евалуације модела без претходног тренирања

<i>Модел</i>	<i>Провера правописа</i>	WER	CER
whisper-large-v2	не	16.647	6.383
whisper-large-v2	да	14.706	6.128
whisper-large-v3	не	12.431	5.077
whisper-large-v3	да	11.372	4.976



Резултати евалуације модела v2 на тест скупу

Број корака	learning_rate	weight_decay	Провера правописа	WER	CER
4000	0.001	None	Не	18.4511	6.8129
4000	0.001	0.001	Не	12.9279	4.94
16000	0.0009	0.001	Не	7.0294	3.2322
16000	0.0009	0.001	Да	6.9413	3.2521



Резултати евалуације модела v3 на тест скупу

Број корака	learning_rate	weight_decay	Провера правописа	WER	CER
16000	0.002	0.001	Не	8.423	3.7497
16000	0.002	0.001	Да	8.0861	3.7444
9000	0.002	0.005	Не	7.5813	3.4662
9000	0.002	0.005	Да	7.3875	3.473

Најбољи резултати евалуације модела v2 и v3

Модел	Провера правописа	WER	CER
whisper-large-v2	не	7.03	3.232
whisper-large-v2	да	6.941	3.252
whisper-large-v3	не	7.581	3.466
whisper-large-v3	да	7.387	3.347



Хвала на пажњи!

